Xây Dựng Hệ Thống Hỏi Đáp Y Khoa Đa Bước Tiếng Việt Dựa Trên Phương Pháp Đồ Thị Tri thức Kết Hợp Với Mô Hình Transformer

Vũ Đình Nhật[1], Hồ Huỳnh Thư Nhi[1], Lê Diễm Quỳnh Như[1], Nguyễn Tấn Hoàng Phước[1]
[1]Trường Đại học Công Nghệ Thông Tin - ĐHQG TP.HCM, Khoa Khoa học và Kỹ thuật Thông tin
23521104@gm.uit.edu.vn, 23521107@gm.uit.edu.vn, 23521122@gm.uit.edu.vn

Tóm tắt

Dự án này nghiên cứu việc xây dựng một hệ thống hỏi–đáp đa bước (multi-hop question answering – QA) cho các câu hỏi y khoa tiếng Việt. Bài toán QA đa bước vẫn còn nhiều thách thức trong lĩnh vực y khoa do sự hạn chế về dữ liệu và các ràng buộc liên quan đến bảo mật thông tin. Để giải quyết vấn đề này, chúng tôi khai thác các bộ dữ liệu y khoa tiếng Việt hiện có nhằm xây dựng các câu hỏi đa bước, yêu cầu mô hình thực hiện suy luận qua nhiều bước trong đồ thị tri thức.

Chúng tôi đề xuất một mô hình lai kết hợp giữa biểu diễn nhúng đồ thị tri thức (Knowledge Graph Embeddings) và kiến trúc Transformer theo hướng Seq-to-Seq nhằm thực hiện suy luận có cấu trúc và hiểu ngôn ngữ tự nhiên. Kết quả thực nghiệm được đánh giá bằng các độ đo chuẩn trong tác vụ hỏi đáp cho thấy hiệu năng tích cực, qua đó khẳng định tính hiệu quả của việc tích hợp tri thức y khoa có cấu trúc với các mô hình ngôn ngữ học sâu.

1 Giới thiệu

Trong những năm gần đây, sự bùng nổ của các mô hình ngôn ngữ lớn và kỹ thuật học sâu đã tạo ra những bước tiến đột phá trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP). Đặc biệt, hệ thống hỏi–đáp (Question Answering - QA) trong lĩnh vực y tế đang được quan tâm nghiên cứu nhờ khả năng hỗ trợ tra cứu thông tin nhanh chóng cho cả người bệnh và đội ngũ chuyên gia. Tuy nhiên, việc áp dụng các mô hình ngôn ngữ thuần túy vào y khoa vẫn đối mặt với hai thách thức lớn: (1) Khả năng suy luận đa bước phức tạp (Multi-hop reasoning) và (2) Rủi ro về tính chính xác của thông tin, thường được biết đến là hiện tượng "ảo giác" (hallucination).

Đối với bài toán y tế, các câu hỏi thường không chỉ dừng lại ở việc tra cứu định nghĩa đơn lẻ mà đòi hỏi sự kết nối tri thức giữa nhiều thực thể như bệnh lý, triệu chứng, dược phẩm và phác đồ điều trị. Ví dụ, để trả lời câu hỏi về sự tương tác giữa một loại thuốc điều trị huyết áp và một tình trạng bệnh nền cụ thể, hệ thống phải thực hiện "nhảy" (hop) qua nhiều nút tri thức khác nhau. Trong bối cảnh tiếng Việt — một ngôn ngữ vốn được coi là khan hiếm tài nguyên (low-resource) trong lĩnh vực NLP — việc thiếu hụt các bộ dữ liệu QA đa bước chất lượng cao càng khiến bài toán này trở nên khó khăn hơn.

Hầu hết các hướng tiếp cận hiện nay thường dựa trên các mô hình dạng "hộp đen" (black-box). Mặc dù các mô hình này có khả năng sinh văn bản trôi chảy, chúng lại thiếu đi tính giải thích (explainability) và thường xuyên bịa đặt thông tin khi đối mặt với những lỗ hổng trong dữ liệu huấn luyện. Điều này gây ra nhiều vấn đề trong lĩnh vực y tế, mỗi thông tin sai lệch đều có thể dẫn đến những hệ lụy nghiêm trọng về sức khỏe.

Xuất phát từ thực trạng đó, nghiên cứu này đề xuất một hệ thống QA đa bước cho y tế tiếng Việt dựa trên sự kết hợp giữa tri thức cấu trúc và mô hình học sâu. Đóng góp chính của bài báo tập trung vào hai khía cạnh:

- **Dữ liệu:** Xây dựng quy trình nhận diện câu hỏi đa bước dựa trên hệ thống quy tắc (Rule-based) định lượng kết hợp đánh giá thủ công bởi con người, tạo ra tập dữ liệu các câu hỏi đa bước từ các nguồn uy tín.

- **Tích hợp tri thức:** Đề xuất mô hình kết hợp giữa biểu diễn nhúng đồ thị tri thức (Knowledge Graph Embeddings) và kiến trúc Transformer nhằm ràng buộc quá trình suy luận vào các dữ kiện thực tế khách quan.

Kết quả thực nghiệm cho thấy việc tích hợp cơ sở tri thức (Knowledge Base) không chỉ giúp tối ưu hóa hiệu suất trả lời mà còn nâng cao đáng kể độ tin cậy của hệ thống, đặt nền móng cho các ứng dụng hỏi-đáp y khoa an toàn và thông minh hơn cho người Việt.

2 Công trình liên quan

Hệ thống hỏi–đáp (Question Answering – QA) là một trong những hướng nghiên cứu cốt lõi của lĩnh vực Xử lý Ngôn ngữ Tự nhiên (Natural Language Processing – NLP). Trong lịch sử phát triển của QA hiện đại,có hai cách tiếp cận chính dựa trên hình thức tạo sinh câu trả lời đã dần được hình thành: extractive và abstractive.

Đối với extractive question answering, công trình nghiên cứu nền tảng là bộ dữ liệu SQuAD (Stanford Question Answering Dataset) (Rajpurkar et al.). Nghiên cứu này tập trung vào việc trích xuất trực tiếp một đoạn (span) từ văn bản nguồn để làm câu trả lời cho câu hỏi, từ đó đặt nền móng cho hướng tiếp cận extractive trong QA hiện đại, mặc dù thuật ngữ này khi đó chưa được sử dụng một cách chính thức.

Song song đó là hướng tiếp cận abstractive question answering, trong đó hệ thống tổng hợp và diễn đạt lại thông tin để tạo ra câu trả lời mới, được thúc đẩy mạnh mẽ bởi bộ dữ liệu MS MARCO (Bajaj et al.) [2]. Khác với SQuAD, MS MARCO sử dụng các câu trả lời do con người viết lại một cách tự nhiên, qua đó hỗ trợ các mô hình sinh ngôn ngữ (generative models) và được xem là một trong những công trình tiên phong cho QA dạng abstractive.

Ngoài phân loại theo cách thức tạo sinh câu trả lời, các hệ thống QA còn được chia theo phạm vi tài liệu thành Open-Domain QA, nơi hệ thống tìm kiếm thông tin từ các nguồn lớn như toàn bộ web hoặc Wikipedia, và Closed-Domain QA, nơi câu hỏi bị giới hạn trong một tập tài liệu hoặc một miền tri thức cụ thể, chẳng hạn như y học hay pháp luật. Bên cạnh đó, dựa trên độ phức tạp của suy luận, QA còn được phân thành single-hop, trong đó câu trả lời có thể được tìm thấy trực tiếp từ một nguồn duy nhất, và multi-hop, trong đó hệ thống phải kết hợp thông tin từ nhiều nguồn hoặc nhiều bước suy luận, như trong bộ dữ liệu HotpotQA (Yang et al., a).

Trong bối cảnh tiếng Việt, đây vẫn được xem là một ngôn ngữ low-resource (khan hiếm tài nguyên), do thiếu hụt các bộ dữ liệu huấn luyện QA quy mô lớn và chất lượng cao so với tiếng Anh. Đặc biệt đối với bài toán multi-hop QA, hiện nay chỉ có một bộ dữ liệu đáng chú ý là ViMQA (Le et al.), được xây dựng dựa trên Wikipedia và tập trung vào các câu hỏi yêu cầu suy luận phức tạp kèm theo lời giải thích.

Ở hướng tiếp cận dựa trên đồ thị tri thức (Knowledge Graph – KG), vốn có ưu thế trong việc tăng cường tính giải thích (explainability) và giảm hiện tượng "ảo giác" (hallucination) – tức là việc mô hình sinh ra các thông tin sai lệch hoặc bịa đặt, đặc biệt nguy hiểm trong các lĩnh vực nhạy cảm như y tế – hiện mới chỉ có một nghiên cứu nổi bật áp dụng cho tiếng Việt là “A New Approach of Question Answering based on Knowledge Graph in Traditional Medicine” (Duong et al.), tập trung vào lĩnh vực y học cổ truyền.

Xuất phát từ những khoảng trống này, nghiên cứu của chúng tôi hướng tới việc kết hợp các ưu điểm của QA đa bước và các phương pháp dựa trên đồ thị tri thức nhằm nâng cao tính giải thích và độ tin cậy của hệ thống hỏi–đáp trong lĩnh vực y tế tiếng Việt. Cụ thể, chúng tôi tập trung vào việc sàng lọc và xây dựng một tập dữ liệu câu hỏi đa bước từ nguồn dữ liệu y tế tiếng Việt, đồng thời phát triển một đồ thị tri thức (knowledge-based graph) để hỗ trợ quá trình suy luận. Cách tiếp cận này cho phép tận dụng sức mạnh của các mô hình học sâu dạng hộp đen (black-box) trong khi vẫn duy trì khả năng giải thích, và nâng cao độ tin cậy của hệ thống QA trong các ứng dụng thực tế.

3 Dữ liệu

Trong nghiên cứu này, chúng tôi sử dụng bộ dữ liệu urnus11/Vietnamese-Healthcare, được công bố trên nền tảng Hugging Face, bao gồm năm bảng dữ liệu được thu thập từ vinmec.com và một số trang tư vấn y tế uy tín khác. Trong số đó, bảng “full” đóng vai trò trung tâm với khoảng 173.000 bản ghi, được hợp nhất từ hai bảng vinmec_article_subtitle và medical_qa.

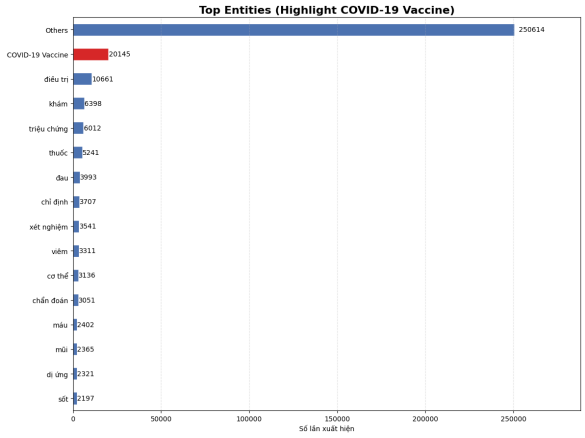

Hình 1: Thống kê các thực thể xuất hiện nhiều trong bộ dữ liệu urnus11/Vietnamese-Healthcare

Thống kê mô tả cho thấy phân bố độ dài của các trường dữ liệu có sự chênh lệch đáng kể. Cụ thể,

trung vị độ dài của trường ngữ cảnh (Context) đạt khoảng 1.423 từ, trong khi độ dài trung bình của câu hỏi và câu trả lời lần lượt là 104 và 496 từ. Bên cạnh đó, phân tích phân bố thực thể trong các cặp hỏi–đáp cho thấy Vaccine COVID-19 là thực thể xuất hiện với tần suất cao nhất. Điều này phản ánh sự mất cân đối rõ rệt về mặt chủ đề trong bộ dữ liệu, khi một số lĩnh vực y tế được đề cập nhiều hơn hẳn so với các lĩnh vực còn lại.

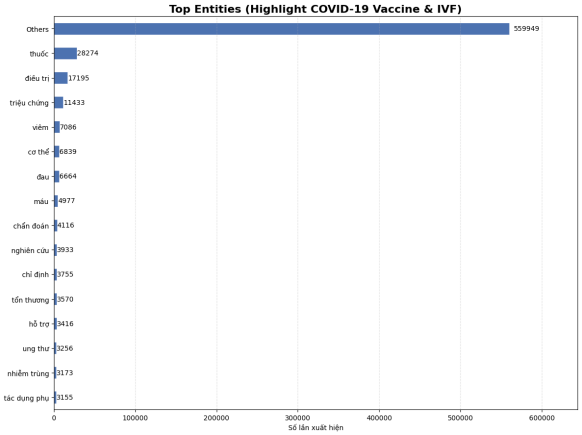

Hình 2: Thống kê các thực thể xuất hiện nhiều trong bộ dữ liệu tmnam20/ViMedAQA

Để khắc phục hạn chế này, thay vì trực tiếp sinh các cặp câu hỏi–câu trả lời từ bộ dữ liệu trên, chúng tôi lựa chọn kết hợp thêm một bộ dữ liệu khác nhằm mở rộng và cân bằng hơn về khía cạnh chủ đề. Bộ dữ liệu bổ sung là tmnam20/ViMedAQA (Tran et al.), cũng được đăng tải trên nền tảng Hugging Face. So với Vietnamese-Healthcare, bộ dữ liệu này có cấu trúc gọn nhẹ hơn, với độ dài trung bình của ngữ cảnh, câu hỏi và câu trả lời lần lượt là 521, 62 và 111 từ; cũng như số lượt xuất hiện của vaccine COVID-19 không còn chiếm phần lớn bộ dữ liệu nữa. Điều này giúp tăng tính đa dạng về nội dung và cải thiện chất lượng dữ liệu phục vụ cho phần thực nghiệm phía sau.

4 Xây dựng cơ sở tri thức và đồ thị tri thức

Trong phần này, chúng tôi mô tả quy trình xây dựng cơ sở tri thức (Knowledge Base) và đồ thị tri thức (Knowledge Graph) từ dữ liệu y khoa tiếng Việt. Quy trình bao gồm bốn giai đoạn chính: truy xuất ngữ cảnh cho các cặp QA, nhận diện thực thể y khoa, trích xuất quan hệ giữa các thực thể và xây dựng Knowledge Graph Embedding.

Hình 3: Cấu trúc một bộ ba (triplet)

4.1 Truy xuất ngữ cảnh cho các cặp QA

Đối với bộ dữ liệu *Vietnamese-Healthcare*, các cặp câu hỏi - câu trả lời (QA) chưa có ngữ cảnh đi kèm, do đó cần thực hiện tác vụ *retrieval* để xác định nguồn kiến thức liên quan. Nhóm đã sử dụng mô hình **BM25** (Best Match 25) để truy xuất các đoạn văn liên quan nhất về mặt ngữ nghĩa đến từng câu hỏi và câu trả lời. Với mỗi QA, top-3 ngữ cảnh được truy xuất để cung cấp nhiều thông tin liên quan nhất cho mô hình.

Trung bình, điểm BM25 của các ngữ cảnh top-3 đạt như sau:

Top-k	Điểm trung bình
Top 1	58.01
Top 2	55.64
Top 3	54.24

Bảng 1: Điểm trung bình BM25 trên top 3 ngữ cảnh truy xuất

Các ngữ cảnh truy xuất được cũng được kiểm tra thủ công. Ví dụ, đối với câu hỏi: *"Đang chích ngừa viêm gan B có chích ngừa Covid-19 được không?"*, ngữ cảnh top-1 được BM25 xác định là:

> *4. Những lưu ý khi chích ngừa viêm gan B*
> *Khi tiêm phòng viêm gan B, chị em cần chú ý đến một số vấn đề sau: Xét nghiệm để kiểm tra xem mình có bị nhiễm virus viêm gan B hay không. Trường hợp chưa bị nhiễm viêm gan B thì sẽ được bác sĩ tư vấn về lịch trình chích ngừa viêm gan B cụ thể...*

Như ví dụ trên, BM25 đã xác định chính xác nguồn kiến thức liên quan đến thực thể *viêm gan B*. Sau khi truy xuất toàn bộ dữ liệu, nhóm tiến hành bước nhận diện thực thể trên dữ liệu gốc.

4.2 Nhận diện thực thể y khoa trong tiếng Việt

Nhóm sử dụng mô hình **VietMed-NER** (Le-Duc et al.), huấn luyện trên dữ liệu y tế tiếng Việt, để nhận diện các thực thể trong câu hỏi, câu trả lời và ngữ cảnh. Mô hình tốt nhất được chọn là xlm-roberta-large-VietMed-NER. Vì bộ dữ liệu gốc có hơn 40 loại thực thể, nhóm chỉ giữ lại 8 loại có

liên quan đến bài toán, với phân phối số lượng như sau:

Loại thực thể	Ý nghĩa	Số lượng (%)
DISEASESYMPTOM	Triệu chứng/bệnh	9578 (46.8%)
DRUGCHEMICAL	Thành phần thuốc	5061 (24.7%)
ORGAN	Cơ quan	2130 (10.4%)
MEDDEVICETECHNIQUE	Thiết bị/kỹ thuật y khoa	1272 (6.2%)
SURGERY	Phẫu thuật	990 (4.8%)
DIAGNOSTICS	Chẩn đoán	738 (3.6%)
TREATMENT	Điều trị	436 (2.1%)
PREVENTIVEMED	Phương pháp phòng ngừa	276 (1.3%)

Bảng 2: Phân bổ loại thực thể sử dụng trong bài toán

Mô hình cũng trích xuất trường canonical_form để chuẩn hóa tên thực thể, giúp giải quyết vấn đề đồng tham chiếu giữa các dạng viết hoa, viết thường hoặc viết tắt. Ví dụ:

```
"ent_00001": {
  "canonical_form": "chích ngừa",
  "entity_type": "PREVENTIVEMED",
  "aliases": ["Chích ngừa"],
  ...
}
```

Như vậy, các thực thể *"chích ngừa"* và *"Chích ngừa"* được nhận diện thống nhất, giảm trùng lặp và tránh gây nhầm lẫn cho mô hình.

4.3 Trích xuất quan hệ giữa các thực thể

Sau khi nhận diện thực thể, bước tiếp theo là trích xuất các quan hệ giữa các thực thể để xây dựng *Knowledge Graph Triplets*. Do chưa có mô hình trích xuất quan hệ dành riêng cho dữ liệu y khoa tiếng Việt, nhóm sử dụng mô hình **ViHealthBERT** (Minh et al.), fine-tune trên dữ liệu y khoa.

Nhóm xây dựng một *schema* quy định các cặp loại thực thể có thể có quan hệ, ví dụ:

```
RELATION_SCHEMA = {
  'TREATED_BY': {
  ('DISEASESYMPTOM','DRUGCHEMICAL'), ... },
  'HAS_SYMPTOM': {
  ('DISEASESYMPTOM','DISEASESYMPTOM'), ... },
  ...
}
```

Bắt đầu từ việc sử dụng phương pháp *Distant Supervision* để tạo nhãn sơ bộ để đưa vào mô hình: các rule-based schema gán nhãn quan hệ cho thực thể, sau đó mô hình được huấn luyện dựa trên các nhãn này. Với 6,379 câu hỏi đa bước sau khi đã nhận diện logic, tổng cộng nhóm trích xuất được 176,158 quan hệ, với phân phối như **Hình 3**.

Sau khi có được dữ liệu về quan hệ và thực thể, nhóm tiến hành chuẩn hóa dữ liệu nhằm đảm bảo chất lượng dữ liệu trước khi đưa vào mô hình. Cụ thể, nhóm tiến hành ba bước:

Loại quan hệ	Số lượng
HAS_SYMPTOM	61,091
TREATED_BY	44,863
DIAGNOSED_BY	23,547
RELIES_ON	17,371
PREVENTED_BY	13,457
AFFECTS	9,648
LOCATED_IN	6,181

Bảng 3: Phân bổ loại quan hệ sau trích xuất

- Canonicalization: đưa các thực thể về dạng canonical_form duy nhất sử dụng hai phương pháp Exact Matching (sử dụng từ điển thay thế các biến thể/từ đồng nghĩa đã biết) và Fuzzy Matching (sử dụng thuật toán Levenshtein để đo độ tương đồng giữa các chuỗi ký tự với ngưỡng trên 90%).

- Lọc điểm tự tin (Confidence Score): Sử dụng ngưỡng 0.995 để lọc ra các triplet có độ tự tin thấp ngưỡng

- Định nghĩa một "danh sách an toàn" (Whitelist) cho triplet: Nhóm lọc ra các bộ triplet và đánh giá thủ công, từ đó định nghĩa được một danh sách gồm 29 schema cho triplets hợp lý nhất.

Ví dụ một schema hợp lý sau giai đoạn lọc thủ công của nhóm:

```
{
  "head_type": "DISEASESYMTOM",
  "relation_type": "DIAGNOSED_BY"
  "tail_type": "DIAGNOSTICS",
  "example_sentences":
    "tiền đình DIAGNOSED_BY KHÁM"
}
```

Kết thúc bước chuẩn hóa, nhóm giữ lại được **44717 bộ ba và 30955 quan hệ**.Nhóm đã xây dựng thành công bộ ba thực thể - quan hệ - thực thể (*entity-relation-entity*) để làm cơ sở cho *Knowledge Graph Embedding*.

4.4 Multi-hop Dataset Engineering

4.4.1 Nhận diện câu hỏi đa bước

Để xây dựng tập dữ liệu đa bước (multi-hop) từ các nguồn *Vietnamese-Healthcare* và *ViMedAQA*, chúng tôi triển khai quy trình nhận diện dựa trên hai giai đoạn: Thống kê thực thể và Hệ thống chấm điểm dựa trên quy tắc (Rule-based scoring).

1. Lọc thực thể dựa trên ngưỡng trung bình: Trước hết, hệ thống tiến hành thống kê số lượng thực thể (n) trung bình trong mỗi câu hỏi. Dựa trên dữ liệu thực nghiệm, giá trị trung bình đạt $\bar{n} = 3.61$

và trung vị đạt 3.00. Chúng tôi tiến hành lọc sơ bộ các câu hỏi có số lượng thực thể lớn hơn giá trị trung bình ($n > 3.61$). Việc này dựa trên giả thuyết rằng mật độ thực thể cao tỉ lệ thuận với số lượng nút (nodes) và cạnh (edges) cần kết nối trên Đồ thị tri thức, từ đó phản ánh đặc trưng của các truy vấn đa bước phức tạp thay vì các câu hỏi đơn lẻ thường chỉ chứa một vài thực thể độc lập. Hành động này giúp hệ thống tập trung nguồn lực vào những mẫu dữ liệu có tiềm năng chứa nhiều mối quan hệ tri thức chồng chéo, tạo tiền đề cho quá trình suy luận đa bước.

2. Hệ thống quy tắc nhận diện (Rule-based): Sau giai đoạn lọc thực thể sơ bộ, các câu hỏi được đưa vào bộ kiểm định định lượng để xác định tính chất đa bước. Chúng tôi xây dựng hàm xác định $IsMultihop$ dựa trên tổng điểm trọng số (S) và số lượng quy tắc thỏa mãn (N_R). Một câu hỏi được dán nhãn là đa bước nếu thỏa mãn điều kiện logic sau:

$$IsMultihop = \begin{cases} S \geq 6 \wedge N_R \geq 2 \\ S \geq 5 \wedge N_R \geq 3 \\ S \geq 4 \wedge N_R \geq 4 \end{cases} \quad (1)$$

Hệ thống bao gồm 9 nhóm quy tắc ($Rule\ 1 \rightarrow 9$) được thiết kế để bóc tách các đặc trưng cú pháp và ngữ nghĩa phức tạp:

- **Rule 1 (Mật độ và đa dạng thực thể):** Đánh giá dựa trên số lượng (E) và số loại thực thể duy nhất (T). Điểm số được cấp lũy tiến: $E \geq 4$ (+3đ), $E = 3$ (+2đ), $E = 2$ (+1đ). Tương tự, sự đa dạng về chủng loại thực thể (T) cũng đóng góp tối đa 3 điểm vào tổng số S.

- **Rule 2 (Liên kết logic):** Sử dụng biểu thức chính quy để nhận diện các từ nối quan hệ (connectors). Các từ nối cơ bản ("và", "hoặc") được tính 1 điểm, trong khi các từ nối điều kiện hoặc thời gian phức tạp ("nếu", "trong trường hợp", "sau khi") được tính 2 điểm.

- **Rule 3 (Cấu trúc cú pháp):** Phân tích độ phức tạp hình thức của câu. Điểm thưởng được áp dụng cho các câu hỏi có nhiều vế (dựa trên số lượng dấu phẩy, dấu chấm phẩy) hoặc các câu hỏi dài vượt ngưỡng 15-20 từ.

- **Rule 4 (Quan hệ nhân quả và giải thích):** Đây là nhóm quy tắc trọng yếu, tập trung vào các động từ/danh từ biểu thị sự tác động y khoa như "gây ra", "dẫn đến", "biến chứng", "hệ quả". Điểm cho nhóm này được tích lũy theo trọng số của từng từ khóa và giới hạn tối đa ở mức 5 điểm.

- **Rule 5-6 (So sánh và Chuỗi hành động):** Nhận diện các cấu trúc đối chiếu ("tốt hơn", "so với") và các quy trình y tế có thứ tự thời gian ("trước tiên", "giai đoạn", "tiếp theo").

- **Rule 7-8 (Độ phức tạp y tế và Pattern đặc biệt):** Tập trung vào các thuật ngữ chuyên sâu về tương tác thuốc, chống chỉ định và các mẫu câu hỏi yêu cầu giải pháp như "phải làm sao", "tác động qua lại".

- **Rule 9 (Phân tích ngữ cảnh thực thể):** Quy tắc này đánh giá sự giao thoa giữa các miền tri thức. Nếu câu hỏi xuất hiện các bộ ba thực thể liên đới như *[Thuốc - Bệnh lý - Phương pháp điều trị]*, hệ thống sẽ tự động cộng thêm 2 điểm để xác nhận tính chất liên kết đa tầng.

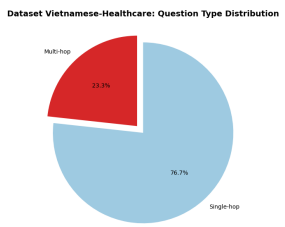

(a) urnus11/Vietnamese-Healthcare

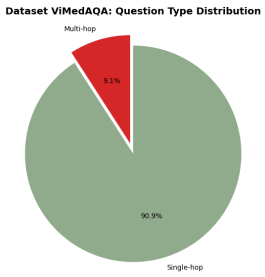

(b) tmnam20/ViMedAQA

Hình 4: Số lượng câu đa bước trong từng bộ dữ liệu

Kết quả của quy trình này cho phép hệ thống trích xuất chính xác **6.379 câu hỏi đa bước** (trong đó có 2.334 câu từ tập *Vietnamese-Healthcare* và 4.045 câu từ tập *ViMedAQA*), tạo thành bộ dữ liệu nền tảng cho việc huấn luyện mô hình suy luận.

4.4.2 Đánh giá chất lượng và Kiểm chứng thủ công

Để đảm bảo độ tin cậy của toàn bộ tập dữ liệu các câu đa bước đã được trích xuất, chúng tôi thực hiện quy trình kiểm soát chất lượng nghiêm ngặt thông qua kiểm chứng thủ công trên 10% tổng mẫu câu hỏi đa bước đã nhận diện:

- **Đánh giá độ đồng thuận:** Nhóm sử dụng chỉ số *Fleiss' Kappa* để đo lường mức độ đồng ý giữa các thành viên gán nhãn, đạt giá trị 0.5592 (mức đồng thuận trung bình khá). Nhãn cuối cùng được quyết định thông qua cơ chế *Major Voting* (Bỏ phiếu đa số).

- **Độ tin cậy thống kê (Statistical Reliability):** Nhằm khẳng định hiệu quả của bộ quy tắc nhận diện trên quy mô toàn thể dữ liệu, chúng tôi áp dụng phương pháp *Wilson Score Interval* để tính toán khoảng tin cậy cho tỷ lệ câu hỏi đa bước xác thực.

  Kết quả kiểm chứng trên mẫu cho thấy tỷ lệ câu hỏi đạt chuẩn multi-hop đạt **80.7%**. Với độ tin cậy 95%, khoảng tin cậy Wilson được xác định trong phạm vi **[77.4%, 83.6%]** với sai số biên (*Margin of Error*) chỉ ở mức $\pm 3.1\%$. Chỉ số này khẳng định rằng bộ quy tắc rule-based có khả năng nhận diện chính xác và ổn định trên toàn bộ dataset, đảm bảo chất lượng dữ liệu đầu vào cho các giai đoạn thực nghiệm tiếp theo.

- **Kiểm soát bias (Bias Control):** Qua phân tích biểu đồ phân phối độ dài câu hỏi (*Question Length Distribution*) - **Hình 5**, chúng tôi nhận thấy sự chồng lấp gần như hoàn toàn giữa phân phối ở tập kiểm chứng (*Annotated sample*) và toàn bộ tập dữ liệu (*Full dataset*). Điều này chứng minh mẫu kiểm chứng có tính đại diện cao và không tồn tại định kiến đáng kể về độ dài câu hỏi.

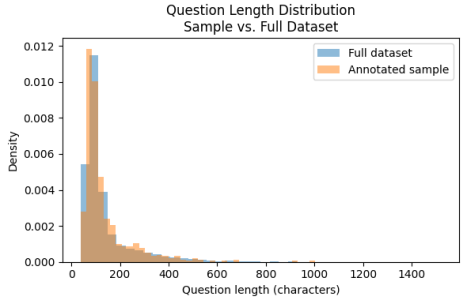

Hình 5: Phân phối độ dài câu hỏi giữa mẫu kiểm chứng và toàn bộ tập dữ liệu

4.5 Xây dựng Knowledge Graph Embedding

Trong giai đoạn này, chúng tôi tiến hành xây dựng *Knowledge Graph* (KG) và chuẩn bị dữ liệu đầu vào cho mô hình *Knowledge Graph Embedding* nhằm phục vụ cho bài toán suy luận đa bước trong miền y tế tiếng Việt.

4.5.1 Trích xuất bộ ba Subject–Predicate–Object

Từ dữ liệu gốc, chúng tôi trích xuất các bộ ba quan hệ (*triple*) theo chuẩn **Subject–Predicate–Object (SPO)**, vốn là định dạng tiêu chuẩn cho các hệ thống Knowledge Graph. Cụ thể, ba cột sau được lựa chọn:

- head_entity_text_canonical: đại diện cho **Subject**
- relation_type: đại diện cho **Predicate**
- tail_entity_text_canonical: đại diện cho **Object**

Sau đó, tên các cột được chuẩn hóa lại để phù hợp với định dạng đầu vào của các thư viện xây dựng Knowledge Graph Embedding. Các giá trị trong dữ liệu cũng được ép về kiểu chuỗi, loại bỏ khoảng trắng dư và lọc các bộ ba chứa giá trị rỗng hoặc độ dài nhỏ hơn hoặc bằng 1 ký tự để giảm nhiễu mô hình embedding.

4.5.2 Xuất dữ liệu cho Knowledge Graph Embedding (PyKEEN)

Sau khi làm sạch, tập dữ liệu được chia thành ba tập con theo tỷ lệ **80% – 10% – 10%** tương ứng với tập huấn luyện, tập kiểm định và tập kiểm tra. Ba tệp dữ liệu đầu ra được lưu dưới định dạng TSV (tab-separated values), không bao gồm dòng tiêu đề, bao gồm:

- training.tsv: 24,764 bộ ba
- validation.tsv: 3,095 bộ ba

- testing.tsv: 3,096 bộ ba

Các tệp này được sử dụng trực tiếp làm đầu vào cho thư viện PyKEEN trong quá trình huấn luyện mô hình Knowledge Graph Embedding.

4.5.3 Xuất dữ liệu cho hệ quản trị đồ thị Neo4j

Bên cạnh việc phục vụ huấn luyện embedding, Knowledge Graph cũng được xuất sang định dạng phù hợp để trực quan hóa bằng hệ quản trị cơ sở dữ liệu đồ thị Neo4j.

Tệp Nodes (neo4j_nodes.csv) Danh sách node được tạo bằng cách trích xuất toàn bộ các thực thể xuất hiện trong cả Subject và Object, sau đó loại bỏ các thực thể trùng lặp dựa trên tên. Tệp node có định dạng gồm hai cột name:ID và :LABEL, với tổng cộng **4,525 node thực thể độc nhất**.

Tệp Relationships (neo4j_relationships.csv) Tệp quan hệ lưu trữ các cạnh trong Knowledge Graph, bao gồm các cột :START_ID, :TYPE, :END_ID và confidence. Tổng số quan hệ được trích xuất là **30,955 relationships**, phản ánh mức độ phong phú của các mối liên hệ y tế trong dữ liệu.

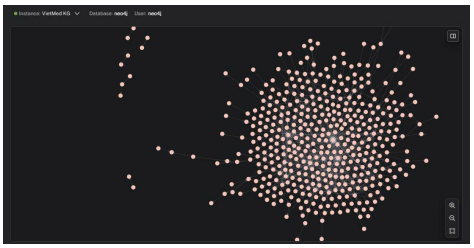

Hình 6: Trực quan hóa dữ liệu bằng đồ thị Neo4j

Kết quả của giai đoạn này là một Knowledge Graph y tế tiếng Việt có cấu trúc rõ ràng, vừa đáp ứng yêu cầu huấn luyện mô hình Knowledge Graph Embedding, vừa sẵn sàng cho việc trực quan hóa và khai thác tri thức.

5 Thực nghiệm và đánh giá

5.1 Mô hình Transformer kết hợp KGE

5.1.1 Mã hóa văn bản

Các dữ liệu văn bản được mã hóa bằng ViT5 Encoder nhằm trích xuất đặc trưng ngữ nghĩa ở mức ngữ cảnh:

$$H_Q = Encoder_{ViT5}(Q) \in R^{n \times d_{model}} \quad (2)$$

$$H_C = Encoder_{ViT5}(C) \in R^{m \times d_{model}} \quad (3)$$

với $d_{model} = 768$.

5.1.2 Mã hóa đồ thị tri thức

Để khai thác thông tin cấu trúc từ đồ thị tri thức $\mathcal{G}$, chúng tôi sử dụng mạng tích chập đồ thị (Graph Convolutional Network – GCN) gồm $L = 2$ lớp. Tại mỗi lớp l, biểu diễn của thực thể v_i được cập nhật theo công thức:

$$h_i^{(l+1)} = \sigma\left(\sum_{j \in \mathcal{N}(i) \cup \{i\}} \frac{1}{\sqrt{\tilde{d}_i \tilde{d}_j}} h_j^{(l)} W^{(l)}\right) \quad (4)$$

trong đó:

- $\mathcal{N}(i)$ là tập các nút láng giềng của thực thể i;
- $\tilde{d}_i$ là bậc của nút i sau khi thêm self-loop;
- $W^{(l)} \in R^{d_{gnn} \times d_{gnn}}$ là ma trận trọng số tại lớp l;
- $\sigma(\cdot)$ là hàm kích hoạt phi tuyến.

Sau L lớp GCN, các biểu diễn thực thể được chiếu tuyến tính để khớp với không gian đặc trưng của mô hình ngôn ngữ:

$$H_{KG} = Linear(h^{(L)}) \in R^{|\mathcal{V}| \times d_{model}} \quad (5)$$

5.1.3 Cơ chế Attention tích hợp tri thức

Dựa trên kiến trúc đề xuất, đặc trưng văn bản đóng vai trò là *Query*, trong khi tri thức từ đồ thị đóng vai trò là *Key* và *Value*.

A. Phép chiếu đa đầu (Multi-Head Projection) Với mỗi đầu attention $h \in \{1, \ldots, 12\}$, các phép chiếu được xác định như sau:

$$\mathrm{Q}_h = H_{text} W_h^Q, \quad K_h = H_{KG} W_h^K, \quad V_h = H_{KG} W_h^V \quad (6)$$

trong đó $W_h^Q, W_h^K, W_h^V \in R^{d_{model} \times d_k}$ và $d_k = d_{model}/12 = 64$.

B. Tính toán Attention Trọng số tương quan giữa đặc trưng văn bản và tri thức đồ thị được tính bằng cơ chế scaled dot-product attention:

$$head_h = Attention(Q_h, K_h, V_h) = softmax\left(\frac{Q_h K_h^\top}{\sqrt{d_k}}\right) V_h \quad (7)$$

C. Tổng hợp và chuẩn hóa Đầu ra từ các head được nối lại và chiếu qua ma trận W^O:

$$\text{MultiHead(Q, K, V)} = \text{Concat(head}_1, \ldots, head_{12})W^O \quad (8)$$

Theo kiến trúc Transformer, đầu ra cuối cùng được tính bằng cách áp dụng kết nối tắt (residual connection) và chuẩn hóa lớp:

$$\mathrm{H}_{out} = LayerNorm\left(H_{text} + Dropout(MultiHead(Q, K, V))\right) \tag{9}$$

Cơ chế trên được áp dụng độc lập cho hai luồng:

- H'_Q: biểu diễn câu hỏi sau khi tích hợp tri thức;
- H'_C: biểu diễn ngữ cảnh sau khi tích hợp tri thức.

5.1.4 Giải mã và sinh câu trả lời

Toàn bộ đặc trưng đã tích hợp tri thức được đưa vào ViT5 Decoder để sinh chuỗi câu trả lời $Y = \{y_1, \ldots, y_T\}$:

$$\mathrm{P}(\mathrm{y}_t \mid y_{<t}, H'_Q, H'_C) = Softmax\Big(Decoder_{ViT5}(y_{<t}, [H'_Q; H'_C])\Big) \tag{10}$$

Hàm mục tiêu của mô hình là cực tiểu hóa mất mát Cross-Entropy:

$$\mathcal{L} = -\sum_{t=1}^{T} \log P(y_t \mid y_{<t}, Q, C, \mathcal{G}) \tag{11}$$

Trong nghiên cứu này, chúng tôi lựa chọn mô hình Transformer làm cơ sở (baseline) do đây là kiến trúc đã được chứng minh hiệu quả rộng rãi trong nhiều bài toán xử lý ngôn ngữ tự nhiên, đặc biệt là các nhiệm vụ sinh văn bản như dịch máy, tóm tắt và hỏi–đáp. Khả năng mô hình hóa thông qua cơ chế self-attention giúp Transformer nắm bắt tốt ngữ cảnh toàn cục của văn bản, qua đó trở thành một chuẩn so sánh phù hợp cho các nghiên cứu mở rộng kiến trúc.

Trên cơ sở đó, chúng tôi đề xuất và đánh giá một biến thể mở rộng của Transformer bằng cách tích hợp biểu diễn tri thức dưới dạng Knowledge Graph Embedding (KGE). Việc bổ sung thông tin tri thức có cấu trúc nhằm tăng cường khả năng nắm bắt quan hệ ngữ nghĩa giữa các thực thể y tế, từ đó kỳ vọng cải thiện chất lượng sinh câu trả lời trong các tình huống đòi hỏi hiểu biết chuyên sâu về miền tri thức. Hai kiến trúc mô hình — **Transformer cơ sở và Transformer tích hợp KGE** — được minh họa chi tiết trong **Hình 7**.

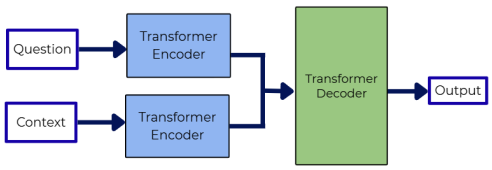

(a) Transformer (Baseline)

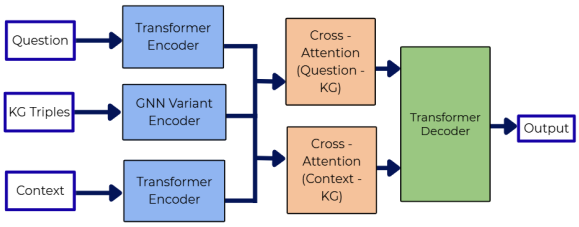

(b) Transformer tích hợp Knowledge Graph Embedding (KGE)

Hình 7: Kiến trúc mô hình

5.2 Kết quả thực nghiệm

Để đánh giá và so sánh hiệu năng của các mô hình một cách toàn diện, chúng tôi sử dụng ba độ đo tiêu chuẩn phổ biến trong các bài toán sinh văn bản, bao gồm **BLEU, ROUGE-L và BERTScore** (Zhang et al.). BLEU và ROUGE-L chủ yếu đo lường mức độ trùng khớp về mặt từ vựng và cấu trúc chuỗi giữa văn bản sinh ra và văn bản tham chiếu, trong khi BERTScore tận dụng biểu diễn ngữ nghĩa theo ngữ cảnh để phản ánh mức độ tương đồng ngữ nghĩa sâu hơn. Việc kết hợp cả ba độ đo cho phép đánh giá đồng thời cả khía cạnh hình thức và nội dung ngữ nghĩa của các câu trả lời.

Mô hình	BLEU	ROUGE-L	BERTScore
Transformer	4.68	25.31	80.59
Transformer + KGE	**28.85**	**51.53**	**89.47**

Bảng 4: Kết quả đánh giá các mô hình

Kết quả định lượng của các mô hình được trình bày trong **Bảng 4**, cho thấy mô hình Transformer khi được kết hợp với tri thức từ đồ thị có khả năng tạo sinh câu trả lời tốt hơn rõ rệt so với Transformer thuần. Tuy nhiên, để đảm bảo rằng sự cải thiện này không chỉ là ngẫu nhiên trên tập kiểm thử, chúng tôi tiếp tục thực hiện kiểm định ý nghĩa thống kê ở mức độ câu (sentence-level) được trình bày trong **Bảng 5**.

Cụ thể, các chỉ số BLEU, ROUGE-L và BERTScore-F1 được tính riêng cho từng cặp câu hỏi–câu trả lời trong tập kiểm thử, từ đó tạo ra các phân phối điểm số ghép cặp giữa hai mô hình. Việc đánh giá ở mức từng câu cho phép chúng tôi kiểm tra trực tiếp xem, trên cùng một tập dữ liệu đầu vào,

Mô hình	BLEU	ROUGE-L	BERTScore
Transformer + KGE	28.85%	51.53%	89.47%
Transformer	4.68%	25.31%	80.59%
p-value	0	0	0
Δ	**24.17%**	**26.22%**	**8.88%**

Bảng 5: So sánh chi tiết giữa các mô hình và kiểm định thống kê

mô hình nào thực sự tạo ra các đầu ra tốt hơn một cách nhất quán.

Đối với BLEU và ROUGE-L, chúng tôi sử dụng bootstrap có ghép cặp (paired bootstrap), do hai độ đo này có phân phối phức tạp, không tuân theo giả định chuẩn và thường không ổn định ở mức câu. Phương pháp bootstrap cho phép ước lượng trực tiếp phân phối của hiệu số giữa hai mô hình bằng cách lấy mẫu lặp lại từ tập câu hỏi–câu trả lời, nhờ đó đưa ra kiểm định tin cậy mà không cần giả định về dạng phân phối.

Ngược lại, BERTScore-F1 là một độ đo liên tục, mượt và có phân phối gần chuẩn hơn khi tính trên tập lớn các câu, do nó dựa trên độ tương đồng embedding thay vì so khớp n-gram rời rạc. Vì vậy, chúng tôi áp dụng paired t-test, một kiểm định tham số phù hợp để so sánh trung bình của hai tập giá trị ghép cặp trong trường hợp phân phối tương đối ổn định.

Kết quả kiểm định cho thấy mô hình **Transformer + KGE vượt trội so với Transformer thuần** trên tất cả các độ đo, và **sự khác biệt này đều có ý nghĩa thống kê**, với toàn bộ p-value xấp xỉ bằng 0. Điều này khẳng định rằng mức cải thiện quan sát được không phải là ngẫu nhiên, mà phản ánh tác động tích cực của việc tích hợp tri thức từ Knowledge Graph vào mô hình sinh câu trả lời.

5.3 Phân tích lỗi

Sau khi thu được kết quả, chúng tôi tiến hành phân tích nhằm xác định các lỗi phổ biến nhất. Qua quá trình thống kê, có thể thấy đây là những lỗi thường gặp trong quá trình thực nghiệm. Đứng đầu là lỗi Truncated Output, tức câu trả lời do mô hình sinh ra bị cắt ngắn. Ba lỗi còn lại gồm Thiếu thực thể (Missing Entities), Câu trả lời không liên quan tới câu hỏi (Irrelevant Responses) và Lặp lại câu hỏi (Restating Question), với số lượng bản ghi lần lượt là 134 và 97 dòng.

Nguyên nhân chủ yếu của các lỗi này xuất phát từ việc nhóm không có nhiều tài nguyên để huấn luyện mô hình, do đó tham số đầu vào được thiết lập ở mức 384 tokens, tham số đầu ra thì sẽ ở mức 128 tokens. Giới hạn này khiến cả câu trả lời gốc (ground truth) lẫn câu trả lời do mô hình sinh ra

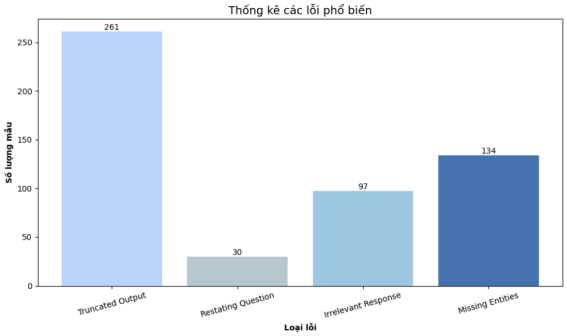

Hình 8: Các lỗi phổ biến trong kết quả thực nghiệm

(predictions) đều bị cắt ngắn, dẫn đến việc mô hình chỉ lặp lại phần đầu của câu hỏi mà chưa kịp trả lời vào trọng tâm nội dung.

Sau đây là một vài ví dụ về các lỗi đã được đề cập như trên.

(a) Trường hợp Irrelevant Response + Missing Entities

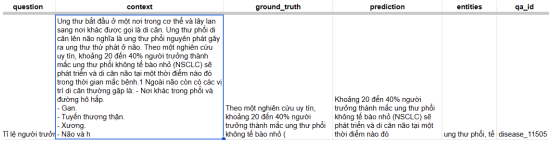

(b) Trường hợp Truncated Output

Hình 9: Ví dụ về lỗi

6 Kết luận và hướng phát triển

6.1 Kết luận

Nghiên cứu này đã trình bày một hướng tiếp cận hiệu quả cho hệ thống trả lời câu hỏi y tế đa bước thông qua việc tích hợp các cơ sở tri thức cấu trúc (Knowledge Base) vào quy trình xử lý ngôn ngữ. Việc kết hợp này không chỉ nâng cao độ chính xác trong truy xuất thực thể mà còn thiết lập một nền tảng vững chắc cho khả năng suy luận logic có căn cứ.

Kết quả thực nghiệm cho thấy, sự kết hợp giữa tri thức y khoa chuyên biệt và các mô hình ngôn ngữ hiện đại giúp hệ thống vận hành tối ưu hơn, đặc biệt trong việc giải quyết các mối liên kết thông tin phức tạp, giúp tối ưu hóa hiệu suất của hệ thống QA y tế đối với các truy vấn đa bước bằng tiếng Việt.

6.2 Hướng phát triển

Trong các giai đoạn phát triển tiếp theo, nhóm nghiên cứu định hướng tối ưu hóa hệ thống thông

qua ba thành phần chiến lược nhằm đảm bảo tính chính xác, minh bạch và an toàn trong ứng dụng y tế thực tiễn:

6.2.1 Tích hợp Module phân loại ý định

Nhóm sẽ bổ sung một tầng tiền xử lý để thực hiện phân loại ý định người dùng ngay tại đầu vào. Module này có nhiệm vụ phân định các nhóm câu hỏi cụ thể như: xác nhận đúng/sai (Yes/No), truy vấn định lượng, yêu cầu định nghĩa ngắn, hoặc yêu cầu giải thích chuyên sâu. Việc định tuyến (Routing) câu hỏi vào các kịch bản xử lý chuyên biệt sẽ giúp tối ưu hóa việc lựa chọn Prompt và chiến lược truy xuất, từ đó tăng tính hiệu quả và giảm thiểu việc sử dụng nhiều tài nguyên cho các câu hỏi chỉ cần câu trả lời ngắn như câu hỏi định lượng hay xác nhận.

6.2.2 Học suy luận thông qua Reasoning Path và Kiểm soát ảo giác

Chúng tôi thiết lập một cơ chế suy luận có ràng buộc thông qua việc sử dụng các đường dẫn truy xuất tri thức (*Reasoning Path*). Thay vì để hệ thống tự do sinh văn bản dựa trên xác suất thống kê, chúng tôi nhúng trực tiếp các chuỗi thực thể và quan hệ khách quan từ cơ sở tri thức vào quá trình tư duy của mô hình. Việc ràng buộc suy luận này giúp người dùng và người lập trình kiểm soát chặt chẽ mạch logic, tạo ra một quy trình ra quyết định dựa trên dữ liệu (*data-driven decision*) minh bạch và có thể kiểm chứng được.

Cơ chế này đóng vai trò là nền tảng cốt lõi cho việc kiểm soát ảo giác (*Anti-hallucination*). Cụ thể, hệ thống triển khai một lớp hậu kiểm (*Post-processing filter*) để đối chiếu câu trả lời cuối cùng với cấu trúc tri thức trong đường dẫn đã trích xuất. Độ tin cậy của câu trả lời được đánh giá dựa trên mức độ tương quan giữa nội dung sinh ra và các liên kết thực thể hiện diện trong đường dẫn đó.

Trong trường hợp phát hiện sự thiếu hụt tri thức hoặc nếu thông tin sinh ra nằm ngoài phạm vi chứng cứ của *Reasoning Path*, cơ chế từ chối thông minh (*Refusal mechanism*) sẽ được kích hoạt với phản hồi chuẩn hóa: *"Dựa trên dữ liệu hiện tại, hệ thống không đủ thông tin chính xác để trả lời..."*. Cách tiếp cận tích hợp này đảm bảo rằng hệ thống chỉ cung cấp những thông tin có căn cứ xác thực, loại bỏ hoàn toàn rủi ro bịa đặt tri thức y khoa gây nguy hiểm cho người dùng.

References

Payal Bajaj, Daniel Campos, Nick Craswell, Li Deng, Jianfeng Gao, Xiaodong Liu, Rangan Majumder, Andrew McNamara, Bhaskar Mitra, Tri Nguyen, Mir Rosenberg, Xia Song, Alina Stoica, Saurabh Tiwary, and Tong Wang. MS MARCO: A human generated MAchine reading COmprehension dataset. *Preprint*, arxiv:1611.09268 [cs].

Pham Van Duong, Tien-Dat Trinh, Hai Van Pham, Tran Manh Tuan, Le Hoang Son, Huy-The Vu, Minh-Tien Nguyen, and Pham Minh Chuan. A new approach of question answering based on knowledge graph in traditional medicine. pages 285–288.

Khang Le, Hien Nguyen, Tung Le Thanh, and Minh Nguyen. VIMQA: A vietnamese dataset for advanced reasoning and explainable multi-hop question answering. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pages 6521–6529. European Language Resources Association.

Khai Le-Duc, David Thulke, Hung-Phong Tran, Long Vo-Dang, Khai-Nguyen Nguyen, Truong-Son Hy, and Ralf Schlüter. Medical spoken named entity recognition. *Preprint*, arxiv:2406.13337 [eess].

Nguyen Minh, Vu Hoang Tran, Vu Hoang, Huy Duc Ta, Trung Huu Bui, and Steven Quoc Hung Truong. ViHealthBERT: Pre-trained language models for vietnamese in health text mining. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pages 328–337. European Language Resources Association.

Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. SQuAD: 100,000+ questions for machine comprehension of text. *Preprint*, arxiv:1606.05250 [cs].

Minh-Nam Tran, Phu-Vinh Nguyen, Long Nguyen, and Dien Dinh. ViMedAQA: A vietnamese medical abstractive question-answering dataset and findings of large language model. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 4: Student Research Workshop)*, pages 252–260. Association for Computational Linguistics.

Rui Yang, Haoran Liu, Edison Marrese-Taylor, Qingcheng Zeng, Yu He Ke, Wanxin Li, Lechao Cheng, Qingyu Chen, James Caverlee, Yutaka Matsuo, and Irene Li. a. KG-rank: Enhancing large language models for medical QA with knowledge graphs and ranking techniques. Version Number: 3.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. b. HotpotQA: A dataset for diverse, explainable multi-hop question answering. *Preprint*, arxiv:1809.09600 [cs].

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. *Preprint*, arxiv:1904.09675 [cs].